

Experimento realizado com diversos classificadores. A Clusterização do sinal foi feita utilizando *Kmeans*, de acordo com o proposto por Wang et al. (2008). Para os teste iniciais, a escolha dos sensores também foi a mesma proposta por Wang et al. (2008).

A segmentação do sinal, para definição das classes foi utilizada a mesma proposta por Tamilselvan and Wang (2013), que consite em: as 50 últimas amostras no sinal correspondem ao estado de falha (HS-4), as amostras entre 51 e 125, distas da falha são o estado de degradação eminente (HS-3). As amostras entre 126 e 200 são consideras estados de transição (HS-2), na qual há pouca diferença entre a condição normal e de falha eminente. A partir da amostras 201, é considera região normal, de regime permanente (HS-1).

Para rodar os experimentos, todos os classificadores foram submetidos a mesma divisão do conjunto de dados, usando *10-fold cross validation*. Os resultados são no conjunto sugerido para treinamento e parametrização, o *FD005 – train*. Não foram usados os conjuntos de teste ou validação disponibilizados.

Os hiperâmetros selecionados para os classificadores foram:

- **KNN**: Distância: euclidiana; Vizinhos: 5;
- **Random Forest**: Número de estimadores: 10; Número máximo de profundidade: N/A; Número máximo de ramificações: N/A; Meta-algorithm: *bagging*;
- **Perceptron - LMS**:  $\eta = 1$ ; Número de épocas: 1000; Tolerancia do erro:  $10^{-4}$ ;
- **Perceptron - SGD**:  $\eta_0 = 0.005$ ; Número de épocas: 1000; Tolerancia do erro:  $10^{-4}$ ; Regularização:  $L_2$ ;  $\alpha : 0.0001$ ;
- **MLP**: Função de ativação: *tanh*;  $\eta_0 = 0.001$ ; Tolerancia do erro:  $10^{-5}$ ; Algoritmo de treinamento: testes com ADAM e L-BFGS; Foi utilizado *random search* para definição do número de neurônios entre 2 e 1000;

Table 1: Results from all classifiers, on the subset of data from Operationa Condition 1. Features are the sensors reading just as reported by Wang et al. (2008)

Classifier	Acc - Train (%)	Acc (%) - Test
KNN	69.71±0.34	55.18±1.87
Random Forest	98.51±1.06	58.01±1.72
Gaussian Naive-Bayes	61.87±0.23	61.55±2.13
Gaussian Linear discriminant	62.42±1.06	62.35±1.25
Gaussian Quadratic discriminant	38.95±9.71	39.39±10.07
Perceptron - LMS	45.61±7.07	45.07±6.98
Perceptron - SGD	56.83±3.44	56.30±3.73
MLP	63.18±0.29	62.70±1.45
Reports on literature		
Ramasso (2009) - HMM - <b>Nota 1</b>	-	69.25
Ramasso and Gouriveau (2010) - HMM + Fuzzy - <b>Nota 2</b>	-	66.25
Zhao et al. (2011) - SVM - <b>Nota 3</b>	-	90
Tamilselvan and Wang (2013) - DBN	-	90.72

**Nota 1:** Utiliza uma versão mais simplista do conjunto de dado com uma condição operacional e dois tipos de falha.

**Nota 2:** O Autor não explica com clareza como chegou ao pontos para segmentação do sinal. Entretanto em um de seus trabalhos anteriores (Ramasso (2009)), o autor utilizou Gaussian Mixture Models (GMM) para segmentar os sinais. Supôs-se que a segmentação utilizada foi a mesma.

**Nota 3:** O Autor não explica quais condições operacionais utilizou. Foram utilizados limites para definições das classes diferente de Tamilselvan and Wang (2013). O artigo é pobre ao explicar detalhes de préprocessamento dos dados. O autor não reporta quais sensores utilizou como atributos.

Table 2: Results from all classifiers, on the subset of data from Operationa Condition 2. Features are the sensors reading just as reported by Wang et al. (2008)

Classifier	Acc - Train (%)	Acc (%) - Test
KNN	69.10±0.54	55.10±0.99
Random Forest	98.42±2.03	56.34±1.36
Gaussian Naive-Bayes	60.15±0.23	56.74±2.12
Gaussian Linear discriminant	63.15±1.06	62.93±1.36
Gaussian Quadratic discriminant	35.54±7.71	29.46±10.59
Perceptron - LMS	54.74±3.04	54.95±6.79
Perceptron - SGD	53.83±3.12	54.76±6.30
MLP	62.90±0.27	62.06±0.12
Reports on literature		
Ramasso (2009) - HMM - <b>Nota 1</b>	-	69.25
Ramasso and Gouriveau (2010) - HMM + Fuzzy - <b>Nota 2</b>	-	66.25
Zhao et al. (2011) - SVM - <b>Nota 3</b>	-	90
Tamilselvan and Wang (2013) - DBN	-	95.80

Table 3: Matriz de confusão da MLP para o conjunto formado pelo regime 1 e pelos sensores sugeridos por Wang et al. (2008).

Labels	Predictions			
	HS-1	HS-2	HS-3	HS-4
HS-1	<b>1.6%</b>	24.06%	74.06%	0.27%
HS-2	0.92%	<b>18.55%</b>	79.95%	0.58%
HS-3	0.53%	5.71%	<b>86.21%</b>	7.55%
HS-4	0.0%	0.0%	23.62%	<b>76.38%</b>

### 0.1. Using different sensors

Table 4: Results from all classifiers on the test subset of data from Operationa Condition 1.  
Features are the readins from sensors [1,2,3,6,8,10,11,12,13,14,19,20]

Classifier	Acc after (%)	Acc before (%)
KNN	57.90±0.27	55.10±0.99
Random Forest	60.51±2.03	56.34±1.36
Gaussian Naive-Bayes	58.28±3.23	56.74±2.12
Gaussian Linear discriminant	63.61±1.33	62.93±1.36
Gaussian Quadratic discriminant	61.39±2.23	29.46±10.59
Perceptron - LMS	56.40±6.25	54.95±6.79
Perceptron - SGD	56.48±2.81	54.76±6.30
MLP	63.70±0.20	62.06±0.12
Reports on literature		
Ramasso (2009) - HMM - <b>Nota 1</b>	-	69.25
Ramasso and Gouriveau (2010) - HMM + Fuzzy - <b>Nota 2</b>	-	66.25
Zhao et al. (2011) - SVM - <b>Nota 3</b>	-	90
Tamilselvan and Wang (2013) - DBN	-	95.80

Table 5: Matriz de confusão da MLP para o conjunto formado pelo regime 1 e pelos sensores [1,2,3,6,8,10,11,12,13,14,19,20]

Labels	Predictions			
	HS-1	HS-2	HS-3	HS-4
HS-1	<b>3.16%</b>	38.05%	58.79%	0%
HS-2	3.84%	<b>26.37%</b>	69.79%	0%
HS-3	0.74%	9.88%	<b>83.55%</b>	5.82%
HS-4	0.0%	0.0%	18.07%	<b>81.93%</b>

## References

- Ramasso E. Contribution of belief functions to hidden markov models with an application to fault diagnosis. In: Machine Learning for Signal Processing, 2009. MLSP 2009. IEEE International Workshop on. IEEE; 2009. p. 1–6.
- Ramasso E, Gouriveau R. Prognostics in switching systems: Evidential markovian classification of real-time neuro-fuzzy predictions. In: Prognostics and Health Management Conference, 2010. PHM'10. IEEE; 2010. p. 1–10.
- Tamilselvan P, Wang P. Failure diagnosis using deep belief learning based health state classification. Reliability Engineering & System Safety 2013;115:124–35.
- Wang T, Yu J, Siegel D, Lee J. A similarity-based prognostics approach for remaining useful life estimation of engineered systems. In: Prognostics and Health Management, 2008. PHM 2008. International Conference on. IEEE; 2008. p. 1–6.
- Zhao D, Georgescu R, Willett P. Comparison of data reduction techniques based on svm classifier and svr performance. In: Signal and Data Processing of Small Targets 2011. International Society for Optics and Photonics; volume 8137; 2011. p. 81370X.